

Interfață bioelectrică pentru sinteză sonoră generativă în timp real

Autor: Andrei Zglimbea, PCON ETI

Coordonator științific: Grigore Alexandru Burloiu & Victor Popa

REZUMAT

Lucrarea prezintă dezvoltarea unei instalații interactive care captează semnale bioelectrice de la o plantă și le transformă, în timp real, în sunet generativ. Sistemul hardware propus utilizează un front-end analogic pentru achiziția semnalelor și un microcontroller pentru preprocesare digitală adaptivă, urmând o strategie de filtrare LMS. Semnalele procesate sunt apoi clasificate folosind un model machine learning antrenat pe o bază de date proprie de înregistrări, evidențiind tipul de interacțiune fizică realizată cu planta.

În Max/MSP, datele sunt utilizate atât pentru modulația parametrilor unui motor de sinteză FM dezvoltat special pentru acest proiect, cât și pentru gestionarea unui sistem de memorie internă, asigurând evoluția dinamică și unică a răspunsului sonor în timp. Rezultatele experimentale validează funcționalitatea și coerența artistică a instalației, propunând noi direcții de explorare în domeniul biointerfețelor pentru exprimare sonoră.

Cuvinte cheie: semnale bioelectrice, procesare digitală adaptivă, sinteză sonoră generativă, machine learning

1. INTRODUCERE

Interacțiunea om-plantă reprezintă un domeniu la intersecția tehnologiei cu biologia și arta sonoră. Proiectul de față propune dezvoltarea unei instalații interactive care transformă în timp real semnalele bioelectrice emise de o plantă într-un răspuns sonor. Sistemul utilizează o interfață analog-digitală pentru achiziția semnalelor, un algoritm de procesare digitală și un model de clasificare de tip machine learning antrenat pe o bază de date proprie.

Pe baza tipului de interacțiune detectat, precum atingerea în diferite moduri sau absența atingerii, sistemul de sinteză sonoră construit în Max/MSP generează sunete specifice, creând o experiență auditivă reactivă și progresivă. Lucrarea documentează etapele hardware, firmware, de dezvoltare a modelului de clasificare și etapa de sound design, propunând un exemplu de integrare între cercetarea științifică și exprimarea artistică.

2. CONȚINUTUL LUCRĂRII

2.1 Obiectivele cercetării

Obiectivul principal al acestei lucrări este dezvoltarea unui sistem complet de interacțiune bioelectrică în timp real, capabil să detecteze și să clasifice tipuri de interacțiuni tactile cu o plantă și să genereze un răspuns sonor corespunzător. În mod specific, cercetarea urmărește:

- Conceperea unei interfețe hardware fiabile pentru achiziția semnalelor bioelectrice
- Extragerea de caracteristici relevante din semnalul digitalizat prin tehnici adaptive de procesare digitală
- Colectarea unui set de date reprezentativ pentru antrenarea și evaluarea mai multor modele de clasificare automată pentru identificarea tipului de interacțiune: T1 – atingere, T2 – atingere repetitivă, T3 – contact direct, Baseline – starea de bază
- Integrarea modelului într-un sistem de sinteză sonoră reactivă folosind Max/MSP;
- Evaluarea performanței modelului și a coerenței audio într-un context artistic interactiv.

2.2 Contextul științific (State of the art)

Explorarea interacțiunilor bioelectrice dintre plante și medii digitale a generat în ultimele decenii un interes crescut, atât în domeniul cercetării științifice, cât și în arta interactivă. Proiecte precum *Music of the Plants*, au demonstrat posibilitatea de a transforma variațiile de conductivitate electrică ale plantelor în sunete muzicale [1]. Ulterior, inițiative ca *Data Garden MIDI Sprout* au propus interfețe comerciale care transformă semnalele bioelectrice în date MIDI, oferind utilizatorilor o modalitate accesibilă de exprimare artistică prin plante [2].

Totuși, majoritatea acestor abordări utilizează mapări simple și directe ale semnalelor în parametri sonori, fără analiză sau interpretare a semnalului, ceea ce limitează posibilitatea unei interacțiuni expresive complexe. În ultimii ani, integrarea metodelor de învățare automată (machine learning) în analiza semnalelor bioelectrice a devenit tot mai prezentă, cu scopul de a înțelege și clasifica răspunsurile fiziologice ale plantelor în mod automatizat. Spre exemplu, lucrări recente au utilizat clasificatori de tip SVM, Random Forest sau rețele neuronale pentru a detecta stări de stres la plante sau tipuri de stimulare [3], [4].

Din perspectiva sintezei sonore generative, Max/MSP a fost adesea utilizat pentru crearea de instalații interactive bazate pe date senzoriale în timp real. Integrarea dintre clasificare automată și control sonor în medii reactive a fost explorată și în contexte de interfețe om-computer [5], însă interfețele om-plantă interactive cu analiză în timp real rămân un domeniu emergent.

Lucrarea de față propune o abordare nouă în acest context, prin dezvoltarea unei instalații care îmbină procesarea digitală adaptivă, clasificarea automată a interacțiunilor fizice cu planta și generarea de sunet în Max/MSP. Această integrare oferă un grad crescut de expresivitate și adaptivitate în răspunsul sonor și propune o metodologie replicabilă pentru cercetarea artistică bazată pe date biofiziologice în timp real.

2.3 Aspecte teoretice și fundamente tehnice

Achiziția semnalelor bioelectrice de la plante se bazează pe principiile electrofiziologiei vegetale, unde diferențele de potențial electric dintre părți ale plantei sau între plantă și sol pot fi

măsurate și analizate. Pentru o achiziție fiabilă, este necesară stabilizarea semnalului printr-un front-end analogic diferențial, completat de un circuit de tip Right Leg Drive (RLD) pentru reducerea zgomotului comun. Conversia analog-digitală este realizată de un microcontroler RP2040, configurat cu o rezoluție de 10 biți și o rată de eșantionare de 200 Hz.

Procesarea digitală aplicată semnalului utilizează un filtru adaptiv de tip *Least Mean Squares (LMS)*, care elimină interferențele și zgomotul de fond prin modelarea predictivă a semnalului de referință (RLD). După filtrare, semnalul este normalizat adaptiv și se extrag în timp real mai multe trăsături semnificative: energia semnalului, rata de schimbare (derivata), media, variația și anvelopa semnalului.

Aceste trăsături sunt completate cu o analiză spectrală prin *Fast Fourier Transform (FFT)*, iar rezultatul este un vector de caracteristici compus din 45 de dimensiuni. Acesta alimentează un model de clasificare de tip *gradient boosting (XGBoost)*, antrenat pe o bază de date proprie formată din 400 de înregistrări (100 pentru fiecare clasă de interacțiune: T1, T2, T3 și Baseline).

Scopul algoritmului este de a detecta în timp real tipul de interacțiune fizică a utilizatorului cu planta și de a-l transforma într-un semnal de control pentru sinteza sonoră. În vederea aplicării practice, modelul de clasificare a fost integrat într-un patch Max/MSP cu ajutorul extensiei *pymax*, facilitând comunicarea directă între modelul Python și mediul de sinteză.

Această abordare oferă o interfață adaptivă și reactivă între utilizator și sistem, unde răspunsul sonor nu este o simplă mapare, ci rezultatul unei interpretări automatizate a comportamentului bioelectric al plantei.

2.4 Soluția propusă

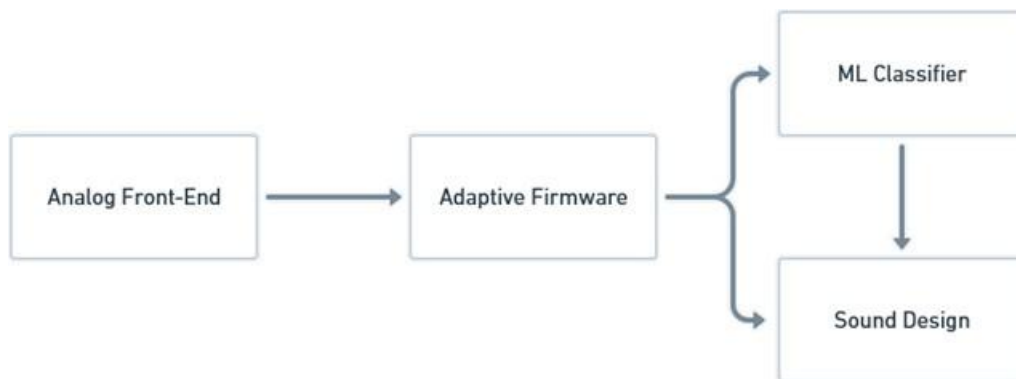


Figura 1. Schema bloc a instalației

2.4.1 Hardware

Sistemul de achiziție este construit în jurul microcontrolerului RP2040, utilizând două canale de conversie analog-digitală de rezoluție 10 biți, cu o frecvență de eșantionare de 200Hz și un amplificator diferențial optimizat pentru semnale bioelectrice. Măsurarea diferențială a semnalului bioelectric este realizată între electrozii plasați pe plantă și referința (RLD), pentru a capta potențialele electrice induse de interacțiunea mecanică asupra plantei. Pentru îmbunătățirea raportului semnal-zgomot și pentru rejectarea zgomotului de mod comun (în special cel indus de rețeaua electrică de 50Hz), am utilizat o arhitectură de tip Right Leg Drive (RLD). Aceasta introduce un semnal de feedback pe referință, cu fază opusă față de zgomotul detectat, stabilizând

astfel nivelul de referință al sistemului și permițând extragerea mai fidelă a semnalului bioelectric.




Figura 2. Schema bloc a interfeței de achiziție

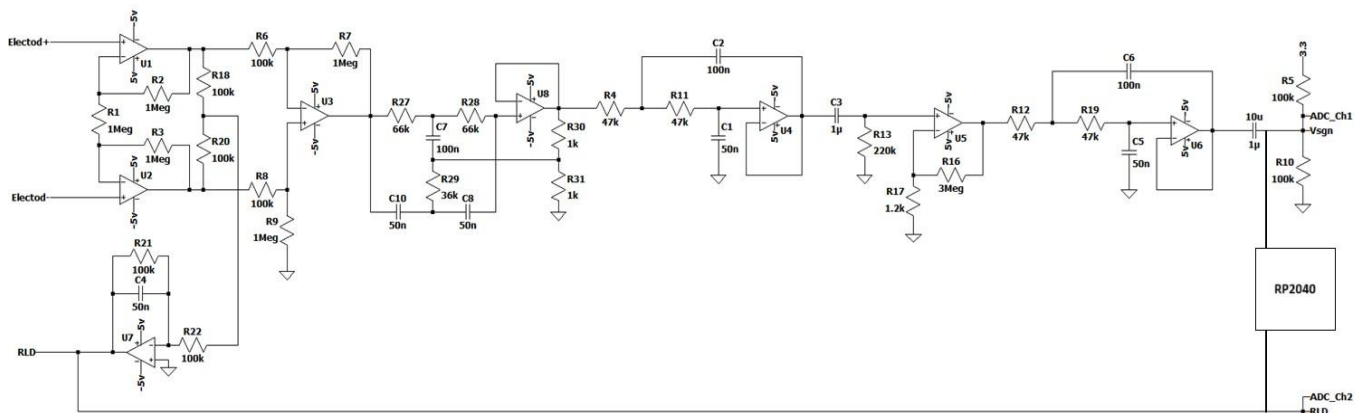


Figura 3. Schema electronică a interfeței de achiziție

Capturile realizate cu osciloscopul digital arată variații semnificative în funcție de tipul de interacțiune, indicând o modificare clară a amplitudinii și a structurii semnalului bioelectric în cazurile de atingere unică, atingere repetitivă sau contact continuu. Aceste observații vizuale au ghidat selecția trăsăturilor extrase și au confirmat fezabilitatea clasificării automate pe baza acestor date.




Figura 4. Capturi osciloscop cu semnalul bioelectric in starea Baseline (stânga), T1 (dreapta)




Figura 5. Capturi osciloscop cu semnalul bioelectric in starea T2 (stânga), T3 (dreapta)

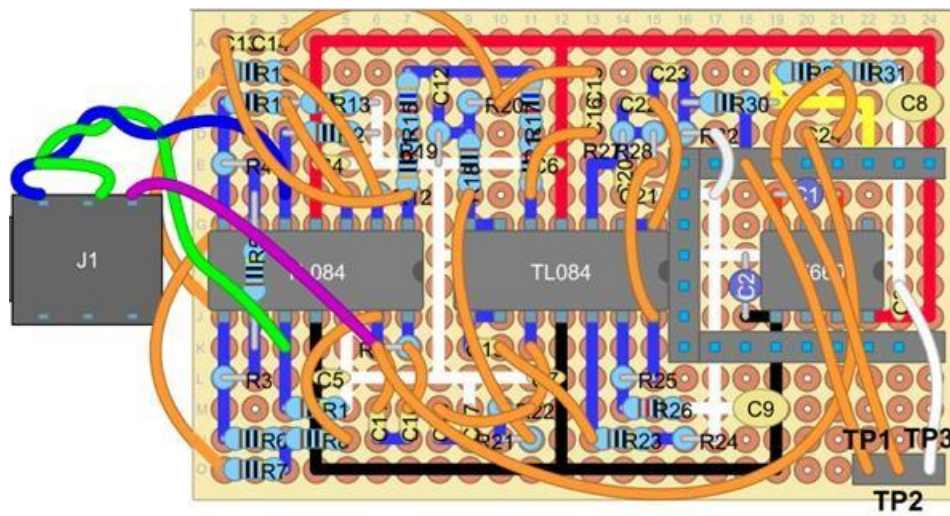


Figura 6. Layout-ul circuitului de achiziție bioelectrică pe veroboard

2.4.2 Firmware

Firmware-ul rulat pe microcontrolerul RP2040 are rolul esențial de a converti semnalul bioelectric analogic într-o reprezentare digitală procesabilă în timp real. Codul este scris în C++ folosind mediul Arduino și este optimizat pentru viteză și stabilitate în procesarea semnalelor slabe provenite de la plante.



Figura 7. Schema bloc a procesării

Semnalul achiziționat este procesat în următoarele etape:

- Eșantionare sincronă: Se utilizează două canale ADC de 10 biți pentru a captura semnalul de la plantă și semnalul de referință (RLD), cu o frecvență de eșantionare de 200Hz, suficientă pentru a surprinde variațiile lente ale activității bioelectrice.
- Eliminarea componentelor DC: Se implementează un algoritm de urmărire a baseline-ului pentru fiecare canal, folosind un filtru de tip IIR de ordinul I. Acesta urmărește lent nivelul mediu al semnalului și îl elimină, lăsând doar variațiile de interes.
- Filtrare LMS (Least Mean Squares): Se aplică o filtrare adaptivă pe semnalul centrat, utilizând semnalul de referință (RLD) ca intrare auxiliară. Aceasta are rolul de a reduce zgomotul de mod comun, în special cel de 50Hz provenit de la rețeaua electrică.
- Normalizare adaptivă: Semnalul filtrat este normalizat dinamic în funcție de amplitudinea maximă recentă, pentru a asigura consistența valorilor în timp.
- Extragerea trăsăturilor: Sunt calculate în timp real trăsături relevante pentru clasificare: semnalul normalizat, viteza de variație, anvelopa, media, variația și energia instantanee
- Transmisie serială: Toate valorile extrase sunt transmise prin portul serial la fiecare eșantion.


2.4.3 Algoritmi pentru Machine Learning

Pentru clasificarea automată a tipurilor de interacțiune, a fost dezvoltat un pipeline complet de învățare automată, bazat pe un set de date colectat experimental, format din 400 de înregistrări (100 pentru fiecare clasă: Baseline, T1, T2, T3). Fiecare fișier .csv conține date bioelectrice procesate în timp real de firmware.

Preprocesare și extragerea de trăsături


Pentru fiecare secvență de date, s-au calculat cinci trăsături în domeniul timp (media, viteza de variație, anvelopa, varianța, energia) și 40 de trăsături în domeniul frecvență, obținute prin aplicarea Transformatei Fourier pe semnalul normalizat. În total, fiecare fereastră de analiză este reprezentată de 45 de trăsături numerice standardizate înainte de a fi introduse în model.

În figura de mai jos este ilustrată compararea dintre semnalul RAW și cel filtrat LMS pentru mai multe trăsături, demonstrând eficiența filtrării adaptive în creșterea raportului semnal/zgomot (SNR), menținând în același timp variația semnificativă a semnalului de interes.



Feature: normalized
 RAW → mean: 0.0029, std: 0.4242, energy: 0.1800, ZCR: 0.5202
 LMS → mean: 0.0049, std: 0.3419, energy: 0.1169, ZCR: 0.2761
 Correlation: 0.4326 | SNR (LMS vs RAW): 0.21 dB

Figura 8. Semnalul normalizat pentru clasa de interactiune Baseline



Feature: rate
 RAW → mean: 0.0070, std: 20.4185, energy: 416.9136, ZCR: 0.5795
 LMS → mean: 0.0066, std: 25.8687, energy: 669.1885, ZCR: 0.5644
 Correlation: 0.8000 | SNR (LMS vs RAW): 2.38 dB

Figura 9. Viteza de variatie pentru clasa de interactiune T3

Compararea modelelor

Pentru a determina cel mai performant algoritm de clasificare, au fost testate mai multe modele, inclusiv: Random Forest, XGBoost. Evaluarea s-a realizat folosind un split de 80% pentru




Figura 10. Compararea modelelor antrenate

antrenare și 20% pentru testare, iar performanța a fost măsurată prin acuratețe și matricea de confuzie.

Modelul final selectat a fost un XGBoost Classifier, obținând o acuratețe de 89% pe setul de test. Acesta a fost salvat împreună cu encoderul de etichete și scalatorul de date și integrat în sistemul Max/MSP printr-un script Python rulat de pachetul pymaxmusic.




Figura 11. Matricea de confuzie a modelului utilizat

Integrare în sistemul Max/MSP

Modelul antrenat rulează în timp real în cadrul unui obiect pyobj, care colectează datele provenite pe portul serial într-un buffer de dimensiune 10000. Predicțiile de înaltă încredere (peste 70%) sunt trimise către sistemul de sinteză sonoră, care reacționează în consecință.

2.4.4 Sound Design

În etapa de sound design, a fost dezvoltat un motor de sinteză FM personalizat în Max/MSP, utilizând două tipuri principale de patch-uri:

- fm_voice0 — un patch cu 6 operatori în paralel, destinat generării de acorduri bogate în gama Do major.
- fm_voice1 — un patch cu 6 operatori conectați într-un algoritm de tip serie, utilizat pentru sunete de tip pluck și texturi dinamice.

Sunetul generat de aceste patch-uri este complet modulat în timp real pe baza semnalelor bioelectrice transmise de plantă prin intermediul conexiunii seriale. Parametrii individuali ai fiecărei voci FM, cum ar fi frecvența operatorilor, indexul de modulație, amplitudinea sau timpul de attack și decay sunt controlați direct de valorile semnalelor procesate (normă, rată, energie, etc.).

Pe lângă sinteza FM, au fost integrate în sistem și înregistrări de teren cu sunete naturale, cum ar fi ciripitul păsărilor. Acestea sunt declanșate sau procesate tot în funcție de datele bioelectrice recepționate.

Un element esențial al sound designului propus este implementarea unui mecanism de memorie:

Instalația nu răspunde doar la inputul instantaneu de la plantă, ci și ține cont de istoricul interacțiunilor precedente. Fiecare nouă reacție sonoră este influențată de evenimentele anterioare, rezultând astfel într-o evoluție sonoră unică, imposibil de reprodus identic de la o sesiune la alta.

Acest principiu de adaptare și memorie a sistemului conferă instalației un comportament organic și imprevizibil, accentuând ideea de colaborare creativă între organismul vegetal și mediul tehnologic.

2.5 Rezultate obținute

În urma dezvoltării și testării prototipului, au fost obținute următoarele rezultate principale:

Interfața hardware de achiziție a semnalelor bioelectrice s-a dovedit fiabilă și stabilă. Design-ul bazat pe amplificare diferențială cu protecție RLD a permis captarea clară a variațiilor de potențial generate de plantă, cu un raport semnal-zgomot optim pentru aplicațiile vizate.

Firmware-ul adaptiv implementat a asigurat o procesare în timp real robustă a semnalelor prin tehnici de normalizare și filtrare adaptivă LMS. Această abordare a dus la îmbunătățirea clară a separabilității între stările de interacțiune, aspect confirmat prin analiza statistică realizată.

Modelul de clasificare machine learning antrenat pe baza datelor colectate a obținut performanțe rezonabile în condiții de laborator, însă în testele de utilizare reală au fost observate fluctuații ale acurateței. Clasificatorul reușește în general să distingă între diferitele tipuri de interacțiuni, dar prezintă ocazional erori de predicție, fenomen explicabil prin variabilitatea naturală a semnalelor bioelectrice.

Din acest motiv, în cadrul etapei de **sound design**, sistemul de clasificare machine learning a fost integrat mai degrabă ca un **factor de memorie** și **modulator de evoluție** a parametrilor sonori, fără a influența în mod brutal și direct sinteza de bază. Astfel, comportamentul instalației sonore variază subtil și progresiv în funcție de istoricul interacțiunilor detectate.

Sunetul generat în timp real în Max/MSP combină semnale sintetizate printr-un motor FM custom (cu mai multe voci independente) și elemente de field recording. Toți parametrii principali de sinteză sunt modulați continuu de valorile preluate de la plantă (normă, rată de schimbare etc.), rezultând o experiență auditivă mereu dinamică și diferită.

În cadrul demonstrației live, sunetul generat în Max/MSP este preluat ulterior în Ableton Live pentru a aplica procesări suplimentare de mixaj și mastering, îmbunătățind coerența și impactul final al instalației sonore.




Figura 12 Interfața dezvoltată (stânga) și instalația completă (dreapta)

3. CONCLUZII

Proiectul a demonstrat fezabilitatea construirii unei instalații interactive care conectează lumea bioelectrică a plantelor cu sinteza sonoră generativă în timp real. Parcurgând toate etapele, de la conceperea unei interfețe hardware stabile și dezvoltarea unui firmware adaptiv, la colectarea de date și antrenarea unui model de clasificare machine learning, s-a reușit realizarea unui sistem capabil să detecteze și să răspundă în mod artistic la interacțiuni tactile cu planta.

Rezultatele experimentale au evidențiat faptul că, deși clasificatorul ML prezintă anumite limitări în condiții reale, integrarea sa într-un sistem de memorie și modulație audio a permis obținerea unei experiențe sonore reactive, fluide și mereu diferite.

LINK Demonstrație: <https://www.youtube.com/shorts/a0tIL53fTJs>

4. BIBLIOGRAFIE

- [1] *Music of the Plants*, Damanhur Research, [Online]. Disponibil: <https://www.musicoftheplants.com>
- [2] J. Park, "MIDI Sprout by Data Garden," *Data Garden*, 2014. [Online]. Disponibil: <https://www.midisprout.com/>
- [3] R. Volkov et al., "Electrophysiological Signaling in Plants: Mechanisms and Use for Monitoring Responses to Stress," *Plant Cell Reports*, vol. 39, pp. 1383–1396, 2020. doi:10.1007/s00299-020-02546-7.
- [4] D. Mishra et al., "Early Detection of Plant Stress Using Machine Learning on Leaf Bioelectrical Signals," *IEEE Access*, vol. 9, pp. 67826–67836, 2021. doi:10.1109/ACCESS.2021.3077209.
- [5] M. M. Wanderley and P. Depalle, "Gestural Control of Sound Synthesis," *Proceedings of the IEEE*, vol. 92, no. 4, pp. 632–644, 2004.